

Phục hồi ảnh vùng khuyết bất quy tắc sử dụng Partial Convolution

Hồ Nhất Trí
22120380

Nguyễn Đình Chuẩn
23120221

Tóm tắt nội dung—Bài báo này nghiên cứu bài toán phục hồi ảnh vùng khuyết (image inpainting), với mục tiêu tái tạo các khu vực bị mất hoặc hư hỏng sao cho kết quả thu được tự nhiên và nhất quán với nội dung ảnh gốc. Phương pháp được đề xuất dựa trên mô hình PConv-UNet (Partial Convolution U-Net), trong đó phép tích chập từng phần cho phép mạng học đặc trưng chủ yếu từ các vùng ảnh hợp lệ và cập nhật thông tin tại những khu vực bị khuyết có hình dạng bất quy tắc. Kiến trúc encoder-decoder kết hợp với các kết nối tắt được sử dụng nhằm bảo toàn thông tin ngữ cảnh và chi tiết không gian trong quá trình tái tạo. Mô hình được huấn luyện trên tập dữ liệu ảnh kết hợp với các mặt nạ ngẫu nhiên, qua đó nâng cao khả năng thích nghi đối với nhiều dạng khuyết ảnh khác nhau trong thực tế.

I. GIỚI THIỆU

Trong những năm gần đây, phục hồi ảnh số ngày càng được quan tâm trong nhiều lĩnh vực như nhiếp ảnh, y tế, giám sát và bảo tồn dữ liệu hình ảnh. Trong quá trình thu nhận, lưu trữ hoặc truyền tải, ảnh có thể xuất hiện các vùng bị mất, che khuất hoặc hư hỏng, làm suy giảm chất lượng thị giác và giá trị khai thác. Vì vậy, phục hồi ảnh vùng khuyết (image inpainting), nhằm tái tạo các khu vực bị thiếu sao cho tự nhiên và nhất quán với nội dung xung quanh, đã trở thành một bài toán quan trọng trong thị giác máy tính.

Tuy nhiên, bài toán này vẫn gặp nhiều thách thức do vùng khuyết thường có hình dạng bất quy tắc, kích thước đa dạng và liên quan đến các cấu trúc ngữ cảnh phức tạp. Các phương pháp truyền thống còn hạn chế trong việc tái tạo kết cấu chi tiết, đặc biệt với các vùng khuyết lớn hoặc phân bố không đều. Trong nghiên cứu này, mô hình PConv-UNet (Partial Convolution U-Net) được sử dụng để khai thác phép tích chập từng phần, cho phép mạng chỉ tính toán trên các điểm ảnh hợp lệ và cập nhật dần vùng cần phục hồi. Mô hình đồng thời được huấn luyện với các mặt nạ bất quy tắc được tạo ngẫu nhiên nhằm tăng khả năng thích nghi với nhiều dạng khuyết ảnh trong thực tế.

II. CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

A. Các phương pháp không dựa trên học máy (Non-learning approaches)

Ở những giai đoạn đầu, các kỹ thuật được dùng trong việc khôi phục ảnh thường dựa vào việc truyền thông tin từ các điểm ảnh lân cận vào vùng bị khuyết thông qua các cơ chế như trường khoảng cách (distance field).

Tuy nhiên, các phương pháp này chỉ có thể xử lý các lỗ hổng hẹp, nơi có sự thay đổi nhỏ về màu sắc và kết cấu. Khi

áp dụng cho các lỗ hổng lớn thì sẽ gặp thách thức do hiện tượng làm mịn quá mức hoặc xuất hiện các vết giả giống với vùng Voronoi.

Các phương pháp dựa trên bản vá (Patch-based methods) ra đời, hoạt động bằng cách tìm kiếm các bản vá phù hợp từ các vùng không có lỗ hổng của hình ảnh hoặc từ các hình ảnh nguồn khác theo cách lặp đi lặp lại, nhưng lại đòi hỏi chi phí tính toán rất lớn. Một trong những thuật toán điển hình là PatchMatch đã giúp cải thiện tốc độ tìm kiếm, nhưng vẫn không đạt đủ nhanh cho các ứng dụng thời gian thực và không thể đưa ra các lựa chọn bản vá có nhận thức về mặt ngữ nghĩa.

B. Các phương pháp dựa trên học sâu

Phương thức tiếp cận bài toán đã thay đổi đáng kể nhờ mạng nơ-ron học sâu. Các mô hình thường khởi tạo các lỗ hổng bằng một số giá trị giữ chỗ (placeholder) không đổi, ví dụ như giá trị pixel trung bình của tập dữ liệu ImageNet, sau đó đưa qua một mạng nơ-ron tích chập.

Thao tác trên thường tạo ra các vết giả, quá trình hậu xử lý thường được sử dụng nhằm giảm thiểu tác động của các giá trị giữ chỗ ban đầu. Điển hình là nghiên cứu Context Encoders nhúng hình ảnh bị khuyết vào một không gian đặc trưng chiều thấp, sau đó giải mã đặc trưng đó để khôi phục lại hình ảnh, tạo tiền đề cho các nghiên cứu sau này.

C. Các phương pháp loại bỏ giá trị giữ chỗ và hạn chế của tích chập tiêu chuẩn

Trong số các phương pháp học sâu, cũng có một số nghiên cứu bỏ qua các giá trị giữ chỗ của mặt nạ (mask placeholder values) như: tiến hành tìm kiếm mã hóa gần nhất trong không gian tiềm ẩn, hoặc tận dụng chính cấu trúc mạng tạo sinh để tự khôi phục ảnh mà không cần tập dữ liệu bên ngoài.

Tuy nhiên, cách tiếp cận này yêu cầu một tập hợp các siêu tham số khác nhau cho mỗi hình ảnh và phải chạy nhiều vòng lặp để đạt kết quả tốt. Hơn nữa, thiết kế đó không thể sử dụng các liên kết vòng (skip links), vốn là yếu tố quan trọng để tạo ra đầu ra chi tiết.

Nhìn chung, nhược điểm lớn nhất khi sử dụng các lớp tích chập tiêu chuẩn là các đặc trưng thô của nhiều hoặc các giá trị khởi tạo lỗ hổng sai ở giai đoạn mã hóa (Encoder) sẽ bị truyền trực tiếp sang giai đoạn giải mã (Decoder), gây ảnh hưởng đến chất lượng ảnh đầu ra.

III. PHƯƠNG PHÁP ĐƯỢC ĐỀ XUẤT

A. Kiến trúc tổng thể của mô hình PConv UNet

Mô hình được xây dựng dựa trên kiến trúc U-Net encoder-decoder [4], trong đó toàn bộ các lớp convolution thông thường được thay thế bằng Partial Convolution theo triển khai tham khảo từ NVIDIA [6]. Kiến trúc tổng thể bao gồm hai thành phần chính là bộ mã hóa (Encoder) và bộ giải mã (Decoder), được kết nối với nhau thông qua các skip connection nhằm bảo toàn thông tin không gian và chi tiết kết cấu của ảnh.

Ảnh đầu vào của mô hình bao gồm ảnh bị khuyết và mặt nạ (mask) tương ứng. Trong đó, mask có giá trị bằng 1 tại các vùng ảnh hợp lệ và bằng 0 tại các vùng bị thiếu dữ liệu. Trong quá trình huấn luyện, ảnh đầu vào được tạo bằng phép nhân giữa ảnh gốc và mask nhằm loại bỏ hoàn toàn thông tin tại các vùng khuyết.

Bộ mã hóa của mô hình có nhiệm vụ trích xuất đặc trưng từ ảnh đầu vào thông qua nhiều tầng Partial Convolution liên tiếp. Kích thước không gian của feature map giảm dần qua từng tầng nhờ việc sử dụng stride bằng 2, trong khi số lượng kênh đặc trưng tăng dần từ 64 đến 512 channels. Quá trình này giúp mô hình học được các đặc trưng ngữ nghĩa ở nhiều mức độ khác nhau, từ các chi tiết biên đơn giản đến các cấu trúc hình học phức tạp.

Sau khi đi qua phần bottleneck, các feature map được đưa vào bộ giải mã nhằm tái tạo lại ảnh hoàn chỉnh. Decoder thực hiện quá trình upsampling để tăng dần kích thước feature map, đồng thời kết hợp với các đặc trưng tương ứng từ encoder thông qua skip connection. Việc kết nối này giúp mô hình khôi phục tốt hơn các chi tiết cục bộ như đường biên, texture và màu sắc của ảnh.

Ở tầng cuối cùng, mô hình tạo ra ảnh phục hồi có cùng kích thước với ảnh đầu vào.

B. Các siêu tham số huấn luyện

Bảng I trình bày các siêu tham số chính được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này được lựa chọn nhằm đảm bảo quá trình tối ưu ổn định, đồng thời phù hợp với kiến trúc PConv-UNet và bài toán phục hồi ảnh vùng khuyết.

Bảng I
CÁC SIÊU THAM SỐ CHÍNH TRONG QUÁ TRÌNH HUẤN LUYỆN

Siêu tham số	Giá trị
Kích thước ảnh đầu vào	256×256
Batch size	16
Số epoch	10
Optimizer	Adam
Learning rate	2×10^{-4}
Hàm mất mát chính	L1 Loss
Perceptual network	VGG16 pretrained
Activation Encoder	ReLU
Activation Decoder	LeakyReLU
Số encoder blocks	8
Số decoder blocks	8
Kiểu convolution	Partial Convolution
Cơ chế skip connection	U-Net skip connection

Hàm mất mát tổng quát của mô hình kết hợp nhiều thành phần nhằm tối ưu đồng thời vùng ảnh hợp lệ, vùng khuyết, đặc trưng tri giác, kết cấu và độ mượt cục bộ của ảnh đầu ra [1], [5]:

$$\mathcal{L} = \mathcal{L}_{\text{valid}} + 6\mathcal{L}_{\text{hole}} + 0.05\mathcal{L}_{\text{perc}} + 120\mathcal{L}_{\text{style}} + 0.1\mathcal{L}_{\text{tv}}. \quad (1)$$

Trong đó, $\mathcal{L}_{\text{valid}}$ và $\mathcal{L}_{\text{hole}}$ lần lượt đo sai khác trên vùng ảnh hợp lệ và vùng bị khuyết; $\mathcal{L}_{\text{perc}}$ và $\mathcal{L}_{\text{style}}$ được tính dựa trên đặc trưng trích xuất từ VGG16; còn $\mathcal{L}_{\text{tv}}$ giúp giảm nhiễu và tăng độ mượt cho ảnh phục hồi. Checkpoint được lưu sau mỗi epoch để hỗ trợ tiếp tục huấn luyện và lựa chọn mô hình tốt nhất.

C. Tập dữ liệu

Trong nghiên cứu này, mô hình được huấn luyện trên tập dữ liệu tổng hợp gồm ảnh khuôn mặt từ CelebA và ảnh cảnh vật từ Places365-Standard nhằm tăng tính đa dạng về ngữ cảnh, cấu trúc và texture. Cụ thể, khoảng 182.000 ảnh CelebA và 180.000 ảnh Places365-Standard được sử dụng cho huấn luyện, trong khi khoảng 20.000 ảnh từ mỗi tập dữ liệu được dùng cho kiểm thử để đánh giá khả năng tổng quát hóa của mô hình.

Ngoài dữ liệu ảnh, bộ NVIDIA Irregular Mask Dataset được sử dụng để tạo vùng khuyết trong quá trình huấn luyện và kiểm thử.

Trong bước tiền xử lý, toàn bộ ảnh và mask được resize về kích thước 256×256 . Mask được chuẩn hóa sao cho vùng ảnh hợp lệ có giá trị bằng 1 và vùng khuyết có giá trị bằng 0 [5].

IV. KẾT QUẢ THỰC NGHIỆM

A. Các độ đo đánh giá

Để đánh giá chất lượng ảnh phục hồi, nghiên cứu sử dụng ba độ đo phổ biến gồm L1 Loss, PSNR và SSIM. Các độ đo này lần lượt phản ánh sai số ở mức pixel, chất lượng tín hiệu và mức độ tương đồng cấu trúc giữa ảnh phục hồi và ảnh gốc.

1) *L1 Loss*: L1 Loss đo sai số tuyệt đối trung bình giữa ảnh phục hồi I_{out} và ảnh gốc I_{gt} . Công thức được biểu diễn như sau:

$$\mathcal{L}_1 = \frac{1}{N} \sum_{i=1}^N |I_{\text{out}}(i) - I_{\text{gt}}(i)|, \quad (2)$$


trong đó N là tổng số pixel. Giá trị L1 Loss càng nhỏ cho thấy sai lệch giữa ảnh phục hồi và ảnh gốc càng thấp.

2) *PSNR*: PSNR (Peak Signal-to-Noise Ratio) đánh giá chất lượng tái tạo ảnh dựa trên tỷ lệ giữa tín hiệu gốc và sai lệch sau phục hồi [2], [7]. PSNR được tính từ sai số bình phương trung bình (MSE) như sau:

$$\text{PSNR} = 10 \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right), \quad (3)$$

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (I_{\text{out}}(i) - I_{\text{gt}}(i))^2, \quad (4)$$

trong đó MAX_I là giá trị pixel lớn nhất của ảnh. PSNR được biểu diễn theo đơn vị decibel (dB); giá trị PSNR càng cao cho thấy ảnh phục hồi càng gần với ảnh gốc và mức nhiễu càng thấp.



Hình 1. Kiến trúc tổng thể của mô hình PConv-UNet sử dụng Partial Convolution trong bài toán phục hồi ảnh vùng khuyết, tham khảo từ [3].


3) *SSIM*: SSIM (Structural Similarity Index Measure) đánh giá mức độ tương đồng cấu trúc giữa ảnh phục hồi và ảnh gốc thông qua ba yếu tố: độ sáng, độ tương phản và cấu trúc không gian [2], [7]. Công thức tổng quát của SSIM giữa hai ảnh x và y được biểu diễn như sau:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}, \quad (5)$$


trong đó μ_x và μ_y là giá trị trung bình, σ_x^2 và σ_y^2 là phương sai, σ_{xy} là hiệp phương sai, còn C_1 và C_2 là các hằng số ổn định. Giá trị SSIM nằm trong khoảng từ 0 đến 1; giá trị càng gần 1 cho thấy ảnh phục hồi càng giống ảnh gốc về mặt cấu trúc và cảm nhận thị giác.

B. Kết quả thực nghiệm

Kết quả đánh giá trên tập kiểm thử cho thấy mô hình đạt L1 Loss trung bình 0.0225, SSIM trung bình 0.8702 và PSNR trung bình 23.10 dB. Các giá trị này cho thấy ảnh phục hồi có sai số pixel khá thấp và giữ được mức tương đồng cấu trúc khá tốt so với ảnh gốc.



Hình 2. Kết quả đánh giá mô hình trên tập kiểm thử: L1 Loss/SSIM trung bình, phân phối PSNR và phân phối SSIM.



Hình 3. Ví dụ kết quả phục hồi ảnh: ảnh gốc, ảnh bị khuyết và ảnh được mô hình tái tạo.

Hình 2 cho thấy L1 Loss đạt 0.0225, phản ánh mức sai lệch thấp giữa ảnh phục hồi và ảnh gốc ở cấp độ pixel. SSIM trung bình đạt 0.8702, tiệm cận mốc chuẩn 0.90, cho thấy mô hình duy trì tương đối tốt cấu trúc không gian, đường biên và texture sau khi phục hồi.

Hình 3 minh họa trực quan khả năng tái tạo vùng khuyết của mô hình trên ảnh thử nghiệm. PSNR trung bình đạt 23.10 dB, với phân phối tập trung chủ yếu trong khoảng 21–25 dB. Điều này cho thấy mô hình tạo ra kết quả phục hồi ổn định trên phần lớn batch kiểm thử. Tuy nhiên, giá trị này vẫn thấp hơn mốc 30 dB, cho thấy ảnh đầu ra vẫn còn tồn tại sai lệch nhất định về chi tiết cường độ sáng hoặc màu sắc, đặc biệt ở các vùng khuyết phức tạp.

Phân phối SSIM tập trung quanh giá trị trung bình 0.8702, với nhiều mẫu nằm gần khoảng 0.85–0.90. Kết quả này chứng tỏ mô hình phục hồi được phần lớn cấu trúc tổng thể của ảnh, nhưng vẫn có thể gặp hạn chế khi tái tạo các chi tiết nhỏ hoặc texture phức tạp.

Nhìn chung, các kết quả thu được cho thấy PConv-UNet có khả năng phục hồi ảnh tương đối hiệu quả, đặc biệt trong việc giữ cấu trúc và giảm sai số pixel. Mặc dù vậy, khoảng cách giữa PSNR trung bình và mốc chất lượng cao cho thấy mô hình vẫn còn dư địa cải thiện, chẳng hạn thông qua tăng số epoch huấn luyện, mở rộng dữ liệu hoặc tinh chỉnh hàm mất mát để nâng cao độ sắc nét và tính tự nhiên của ảnh phục hồi.

TÀI LIỆU

- [1] A. W. Harley, K. G. Derpanis, and I. Kokkinos, “Segmentation-aware convolutional networks using local attention masks,” in *Proc. IEEE International Conference on Computer Vision (ICCV)*, vol. 2, p. 7, 2017.
- [2] GeeksforGeeks, “Performance metrics for image steganography,” [Online]. Available: <https://www.geeksforgeeks.org/computer-networks/performance-metrics-for-image-steganography/>.
- [3] AGU Publications, “pconv_unet_structure.jpg,” [Online]. Available: <https://agupubs.onlinelibrary.wiley.com/doi/full/10.1029/2021GL093096>.
- [4] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Proc. International Conference on Medical Image Computing and Computer-Assisted Intervention*, pp. 234–241, Springer, 2015.
- [5] G. Liu, F. A. Reda, K. J. Shih, T.-C. Wang, A. Tao, and B. Catanzaro, “Image inpainting for irregular holes using partial convolutions,” arXiv:1804.07723, 2018. [Online]. Available: <https://arxiv.org/abs/1804.07723>.
- [6] NVIDIA, “Partial Convolution Layer for Padding and Image Inpainting,” GitHub repository. [Online]. Available: <https://github.com/NVIDIA/partialconv>. Accessed: May 14, 2026.
- [7] Hữu Đạt, “Các chỉ số đánh giá được sử dụng cho bài toán Image Generation: IS, FID, PSNR, SSIM,...,” Viblo, Jun. 11, 2022. [Online]. Available: <https://viblo.asia/p/cac-chi-so-danh-gia-duoc-su-dung-cho-bai-toan-image-generation-is-fid-psnr-ssim-3P0IPJXPKox>. Accessed: May 14, 2026.